

Conception et développement d'une application
d'annotation thématique dans l'environnement Gate

Charles Follet Roland Bary

1^{er} avril 2015

Remerciements

Table des matières

1	Introduction	5
2	Problématique	7
3	État de l’art	9
1	Connaissances	9
2	Outils	9
4	Résolution	11
I	Annotations	11
1	Spatiales	11
2	Temporelles	12
3	Thématiques	15
5	Conclusion	19

Chapitre 1

Introduction

La production de documents se fait de plus en plus rapidement et facilement avec la multiplication des moyens numériques mis à notre disposition. Aujourd'hui, chacun peut écrire ce qu'il veut, quand il le veut et le publier quasi instantanément.

Cette liberté est une avancée certaine dans le domaine de la communication. Mais, alors qu'il est possible de chercher des mots via notre éditeur de texte préféré comment faire des recherches un peu plus avancées ?

Chapitre 2

Problématique

”Comment effectuer des recherches avancées sur un corpus de document non structuré ?”

Chapitre 3

État de l'art

1 Connaissances

2 Outils

Chapitre 4

Résolution

I Annotations

Ébauches des règles d'annotation.

1 Spatiales

Villes, Départements, Pays

2 Temporelles

Les annotations temporelles concernent uniquement des périodes. Parmi ces périodes, on distingue celles d'émission des monnaies et celle de règne des souverains.

Périodes

■ *Vulgarisation :*

Période : intervalle de deux dates séparées par un tiret.

Exemple :

757/8-786

Date : trois et seulement trois chiffres. Peut être suivie d'un « / » et d'un chiffre traduisant l'incertitude sur la date.

Une période est un intervalle de deux dates. Dans notre travail, les dates sont constituées de trois et seulement trois chiffres. Chacune d'entre elle peut, en cas d'ambiguïté, être suivie d'un « / » et d'un chiffre traduisant l'indétermination de la période.

Exemple :

757/8

■

■ *Formalisation :*

Date

$([0-9]\{3\} \setminus / ? [0-9] ?)$

Période

$([0-9]\{3\}(\setminus / [0-9])?) - ([0-9]\{3\}(\setminus / [0-9])?)$

Exemple :

"Type de 771-793/4 : Charlemagne (768-814),..."

Group #1 : 771

Group #2 : 793/4

Group #1 : 768

Group #2 : 814

// Code JAPE

```
import javax.swing.JApplet;
import java.awt.Graphics;
```

```
public class Hello extends JApplet {
    public void paintComponent(Graphics g) {
        g.drawString("Hello, world!", 65, 95);
    }
}
```



Périodes d'émission

■ *Vulgarisation :*

Périodes d'émission : « Type de {Période} : » (Période étant l'annotation définie précédemment). Il faut sécuriser la capture de la période pour ne pas récupérer toutes les périodes du document mais seulement celles correspondants à l'émission de monnaie en ajoutant la contrainte "précédée de Type de".



■ *Formalisation :*

Périodes d'émission :

Type de : $([0-9]\{3\}(\backslash/[0-9])?) - ([0-9]\{3\}(\backslash/[0-9])?)$

Exemple :

"Type de 771-793/4 : Charlemagne (768-814)..."

Group #1 : 771

Group #2 : 793/4



Périodes de règne

■ *Vulgarisation :*

Périodes de règne : « Nom_souverain {Période} : ». Il faut aussi sécuriser la capture grâce aux noms des souverains. Ceux-ci étant difficiles capter via une expression régulière, il faut créer un gazetier contenant tous les souverains. Ensuite, dès qu'une correspondance avec le gazetier sera établie on captera la période immédiatement après.

Exemple :

"Type de 771-793/4 : Charlemagne (768-814)..."



■ *Formalisation :*

Périodes de règne :

Nom_souverain ([0-9]{3}(\/[0-9])?)-([0-9]{3}(\/[0-9])?)

Exemple :

” Type de 771-793/4 : Charlemagne (768-814)...”

Correspondance : Charlemagne

Group #1 : 768

Group #2 : 814



3 Thématiques

Nature de la monnaie

■ *Vulgarisation :*

Nature de la monnaie : toujours un élément de l'ensemble Denier, Obole, Monnaie D'Or, Faux obole suivi ou non du nom d'un souverain. Il suffit donc d'utiliser une expression composée de tous les mots de l'ensemble. Nous vérifions qu'ils y a bien des espaces avant les termes recherchés afin d'augmenter la robustesse de notre recherche. Les noms des souverains seront trouvés à l'aide d'un gazetier.

Exemple :

"Obole de Charles le Chauve"



■ *Formalisation :*

Nature de la monnaie :

`[\\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole)(.*)? Nom_Souverain`

Exemple :

"Obole de Charles le Chauve"

Correspondance : Charles le Chauve

Group #1 : 768

Group #2 : 814



Légende

■ *Vulgarisation :*

Légende : toujours à la ligne qui suit la nature de la pièce. Le revers droit est situé au début de cette ligne et commence par zéro ou un caractère +. Ensuite, vient une suite de 2 espaces ou plus. Pour finir, le revers droit vient se placer après zéro ou un caractère +.

Exemple :

"Denier de Charlemagne

+ CARLO 45ECROIX SIMPLE"



■ *Formalisation :*

Légende :

1. Se positionner à la ligne qui suit la nature de la pièce

`(?:Denier|Obol|Monnaie d'or).*\n`

2. Capturer l'ensemble des caractères entre 0 ou 1 symbole + et 2 ou plus espaces. C'est la légende du droit.

`\+?\s?(.*)[]{2,}`

3. Capture l'ensemble des caractères entre 0 ou 1 symbole + et la fin de ligne. C'est la légende du revers.

`\+?\s?(.*)`

On obtient une expression comme suit :

`(?:Denier|Obol|Monnaie d'or).*\n\s*\+?\s?(.*)[]{2,}\s*\+?\s?(.*)`

Exemple :

"Denier de Charlemagne

+ CARLO 45ECROIX SIMPLE"

Group #1 : CARLO 45E

Group #2 : CROIX SIMPLE



Types monétaire

■ *Vulgarisation :*

Le type monétaire est la simple concaténation de l'ensemble de mots "Type de" avec la période d'émission.

Exemple :

"Type de 771-793/4 : Charlemagne (768-814),..."



■ *Formalisation :*

`(Type de [0-9]{3}\/?[0-9]?-[0-9]{3}\/?[0-9]?)`



Ateliers■ *Vulgarisation :*

Le catalogue est décomposé en ateliers, chaque début de "partie" ou "chapitre" est donc le nom de l'atelier. Ce nom correspond à un endroit géographique. Ce lieu peut être une ville, un lieu-dit, ... Il est difficile de trouver un pattern via les expressions régulières. Il faut constituer un gazetier.

**Personnages**■ *Vulgarisation :*

Les personnages ont des formats aussi diverses que variés, il serait difficile d'utiliser une expression régulière. Il est plus judicieux d'utiliser un gazetier ici.

**Collections, Trésors, Trouvailles**■ *Vulgarisation :*

Collections, Trésors, Trouvailles : sont chacun suivis de deux points. Ensuite vient le contenu concernant ces mots. Le contenu s'arrête lorsqu'on rencontre un point suivi d'un retour à la ligne ou bien d'un autre *mot* suivi de deux points.

■ *Formalisation :*

`Mot_a_trouver:((?:.|\\n)+?)(?:\\.\\s?\\n|\\w:)`

Exemple :

"*Collections : Berlin 1,77, 1,70, 1,59, 1,55 ; MEC 853 (1,78) ; Monnaie de Paris 105 (1,63) ; Prou 584 (1,58), 585 (1,69), 586 (1,79), 587 (1,72), 588 (1,77). Trésors :*"
 Group #1 : Berlin 1,77, 1,70, 1,59, 1,55 ; MEC 853 (1,78) ; Monnaie de Paris 105 (1,63) ; Prou 584 (1,58), 585 (1,69), 586 (1,79), 587 (1,72), 588 (1,77).
 Trésors :



Chapitre 5

Conclusion