# CONCEPTION ET DÉVELOPPEMENT D'UNE APPLICATION D'ANNOTATION THÉMATIQUE

dans l'environnement Gate

Charles Follet Roland Bary

Université de Pau et des Pays de l'Adour

### INTRODUCTION

Annotation sémantique : phase en amont de la recherche d'information sémantique

#### INTRODUCTION

- Annotation sémantique : phase en amont de la recherche d'information sémantique
- Utilisation de la plate-forme GATE Developer

#### INTRODUCTION

- Annotation sémantique : phase en amont de la recherche d'information sémantique
- Utilisation de la plate-forme GATE Developer
- Problématique : comment annoter de manière automatique un document texte non-structuré ?

# **SOMMAIRE**

Compréhension du domaine

Annotations dans GATE

Mise en œuvre

Visualisation

Démonstration



# COMPRÉHENSION DU DOMAINE - LA RESSOURCE

# Recherches sur le Numéraire Carolingien de Georges DEPEYROT.



# Pouvoir répondre aux questions suivantes:

- Temporelles : Quelles étaient les pièces en circulation de l'an 859 à l'an 865 ?
- Thématiques: Combien d'exemplaires de la monnaie d'or de Charles le Chauve ont été étudiés? Dans quels ateliers, les pièces de type Obole de Charlemagne ont été produites?

# COMPRÉHENSION DU DOMAINE - L'OCRISATION

Etape d'OCRisation du numéraire.



# COMPRÉHENSION DU DOMAINE - STRUCTURE DU NUMÉRAIRE

#### Agen (Lot-et-Garonne)

Trouvailles: Bolsward, 1 ex. (H. 528) (1,26).

# COMPRÉHENSION DU DOMAINE - L'ATELIER

### Agen (Lot-et-Garonne)

# COMPRÉHENSION DU DOMAINE - LE TYPE

Agen (Lot-et-Garonne)

#### Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

# COMPRÉHENSION DU DOMAINE - LA NATURE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

#### Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

# COMPRÉHENSION DU DOMAINE - LA LÉGENDE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814) Denier de Charlemagne (24 exemplaires étudiés)

#### + CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

# COMPRÉHENSION DU DOMAINE - LES COLLECTIONS

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;

Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735

(1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60),

794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex.

# COMPRÉHENSION DU DOMAINE - LES TRÉSORS

Agen (Lot-et-Garonne)

# COMPRÉHENSION DU DOMAINE - LES TROUVAILLES

Agen (Lot-et-Garonne)

# COMPRÉHENSION DU DOMAINE - SCÉNARIO D'ANNOTATION

#### Texte en entrée de notre chaîne de traitement

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

# COMPRÉHENSION DU DOMAINE - SCÉNARIO D'ANNOTATION

# Texte en sortie de notre chaîne de traitement

Domaine annoté : Temporel .

Agen (Lot-et-Garonne)

Type de 793/4-812 : Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme
Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

# COMPRÉHENSION DU DOMAINE

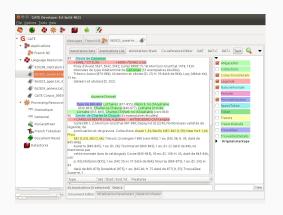
# Texte en sortie de notre chaîne de traitement

Domaine annoté : Thématique

```
Agen (Lot-et-Garonne)
 Type de 793/4-812 : Charlemagne (768-814)
 Denier de Charlemagne (24 exemplaires étudiés)
 + CARLVS REX FR croix
                           + AGINNO monogramme
Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;
 Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735
 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60),
 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex.
 (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);
Trouvailles: Bolsward, 1 ex. (H. 528) (1,26).
```

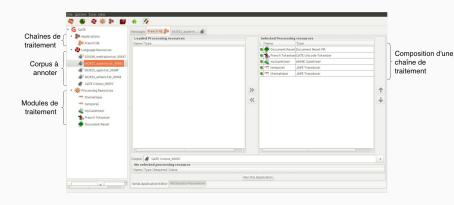
# ANNOTATIONS DANS GATE

### ANNOTATIONS DANS GATE

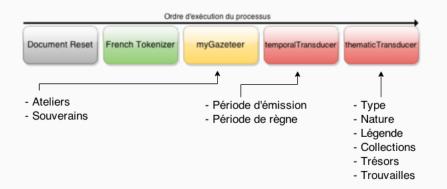


- Outil de traitement automatique du langage (en JAVA)
- Université de Sheffield depuis 1995 (version 8)
- Principe: Chaîne de traitement (Pipeline)
- Plusieurs modules dans un pipeline
- ANNIE: Pipeline par défaut pouvant servir de chaîne de départ

#### ANNOTATIONS DANS GATE



La chaîne de traitement LANG (L'Annotation du Numéraire dans Gate)





■ Document reset : Réinitialisation du document



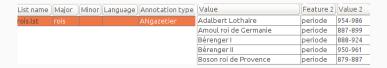
- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots



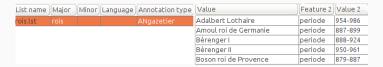
- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots
- MyGazetter : Identification de noms d'entités par Gazetier



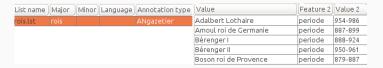
- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots
- MyGazetter : Identification de noms d'entités par Gazetier
- temporal/thematic Transducer : Repérage d'entités nommées inconnues en fonction de modèles d'extraction écrits en langage JAPE



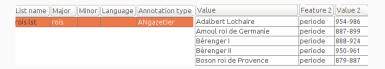
■ Liste de noms d'entités



- Liste de noms d'entités
- Permettant un repérage d'occurrences dans un texte



- Liste de noms d'entités
- Permettant un repérage d'occurrences dans un texte
- Possibilité d'associer des caractéristiques à chaque nom d'entité



- Liste de noms d'entités
- Permettant un repérage d'occurrences dans un texte
- Possibilité d'associer des caractéristiques à chaque nom d'entité
- Dans Gate: MajorType, MinorType réutilisables dans une règle *JAPE*

# ANNOTATIONS DANS GATE - LE FORMALISME JAPE

- Règles JAPE en deux blocs
- Partie gauche (LHS): définition d'un motif d'annotation à repérer
- Partie droite (RHS): Opérations sur un motif (Code JAVA éventuel)
- Utilisation d'un système de Macros



# MISE EN ŒUVRE - DÉMARCHE

1. Langage naturel

français

# MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier

français

expressions régulières

# MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

expressions régulières

JAPE

Annotation : La période d'émission

Exemple 1 : *Type de 793/4-812* 

# Type de 793/4-812

#### 1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois chiffres. En cas d'ambiguïté, une date peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

# Type de 793/4-812

#### 1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois chiffres. En cas d'ambiguïté, une date peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

Type de **793/4**-812

# 2. LANGAGE RÉGULIER

Type de **793/4-**812

# 2. LANGAGE RÉGULIER

Type de 793/4-812

# 2. LANGAGE RÉGULIER

Type de 793/4-812

## 2. LANGAGE RÉGULIER

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Rule: PeriodeRule
((DATE):d1((Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = { [**..*/]
```

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind==number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind==number,Token.length == 1})
Macro:SLASH
({Token.string=="/"})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

Annotation : La nature de la monnaie

Exemple 2 : Obole de Carloman

## Obole de Carloman

#### 1. LANGAGE NATUREL

La nature de la monnaie est toujours un élément de l'ensemble {Denier, Obole, Monnaie D'Or, Faux obole, Monnaies de type indéterminé} suivi du nom d'un souverain. Il suffit donc d'utiliser une expression composée de tous les mots de l'ensemble.

# Obole de Carloman

## 2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (\*)

Nom\_Souverain

# Obole de Carloman

## 2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (.\*)

Nom\_Souverain

# Obole de Carloman

## 2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (.\*) Nom\_Souverain

#### Obole de Carloman

```
Macro: MONNAIE

(
({Token.string == "Obole"})|
({Token.string == "Denier"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Monnaies_de_type_indéterminé"})
)

Macro: LIAISON
((Token.string == "de"))

Macro: LIAISON
((Token.string == "de"))
```

#### Obole de Carloman

```
Macro: MONNAIE

(
({Token.string == "Obole"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Faux_Obole"})|
({Token.string == "Monnaies_de_type_indéterminé"})
)

Macro: LIAISON
({Token.string == "de"})

Macro: LIAISON
({Token.string == "de"})
```

# Obole de Carloman

```
Macro: MONNAIE

( ({Token.string == "Obole"})| ({SpaceToken})?(MONNAIE):monnaie
({Token.string == "Monnaie_d'or"})| ({SpaceToken})(LTAISON)({SpaceToken})
({Token.string == "Monnaie_d'or"})| ({ANgazetier.majorType == "rois"})
({Token.string == "Monnaies_de_type_indéterminé"}) ):NatureMonnaie
) :NatureMonnaie.NatureMonnaie = {/* ... */}

Macro: LIAISON
({Token.string == "de"})
```

# MISE EN ŒUVRE - RÉSULTAT

# Résultat d'annotation

Fichier XML:

<PeriodeEmission>Type de 793/4-812</PeriodeEmission>

<NatureMonnaie>Obole de Carloman</NatureMonnaie>

# MISE EN ŒUVRE - RÉSULTAT

# Résultat d'annotation

Fichier XML:

<PeriodeEmission>Type de 793/4-812</PeriodeEmission>

<NatureMonnaie>Obole de Carloman</NatureMonnaie>

Comment visualiser les annotations en dehors de GATE?

# MISE EN ŒUVRE - RÉSULTAT

# Résultat d'annotation

Fichier XML:

<PeriodeEmission>Type de 793/4-812</PeriodeEmission>

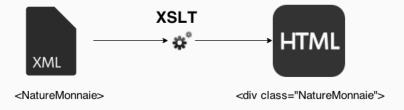
<NatureMonnaie>Obole de Carloman</NatureMonnaie>

Comment visualiser les annotations en dehors de GATE?

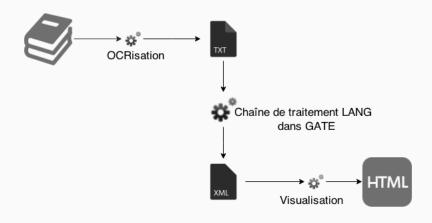
XSLT



# **VISUALISATION**



# DÉMONSTRATION



■ Chaîne de traitement et visualisation fonctionnelles

- Chaîne de traitement et visualisation fonctionnelles
- Besoins du cahier de charges satisfait

- Chaîne de traitement et visualisation fonctionnelles
- Besoins du cahier de charges satisfait
- Améliorations possibles sur :

- Chaîne de traitement et visualisation fonctionnelles
- Besoins du cahier de charges satisfait
- Améliorations possibles sur :
  - · L'interface web de visualisation

- Chaîne de traitement et visualisation fonctionnelles
- Besoins du cahier de charges satisfait
- Améliorations possibles sur :
  - · L'interface web de visualisation
  - · Performance de la chaîne de traitement