CONCEPTION ET DÉVELOPPEMENT D'UNE APPLICATION D'ANNOTATION THÉMATIQUE dans l'environnement Gate

Charles Follet Roland Bary

Université de Pau et Pays de l'Adour

INTRODUCTION

Annotation sémantique : phase en amont de la recherche d'information sémantique

INTRODUCTION

- Annotation sémantique : phase en amont de la recherche d'information sémantique
- Utilisation de la plate-forme GATE Developper

INTRODUCTION

- Annotation sémantique : phase en amont de la recherche d'information sémantique
- Utilisation de la plate-forme GATE Developper
- Problématique : comment annoter de manière automatique un document texte non-structuré ?

SOMMAIRE

Compréhension du domaine

Annotations dans GATE

Mise en œuvre

COMPRÉHENSION DU DOMAINE

COMPRÉHENSION DU DOMAINE - LA RESSOURCE

Recherches sur le Numéraire Carolingien de Georges DEPEYROT.



Pouvoir répondre aux questions suivantes:

- Temporelles : Quelles étaient les pièces en circulation de l'an 859 à l'an 865 ?
- Thématiques: Combien d'exemplaires de la monnaie d'or de Charles le Chauve ont été étudiés? Dans quels ateliers, les pièces de type Obole de Charlemagne ont été produites?

COMPRÉHENSION DU DOMAINE - L'OCRISATION

Etape d'OCRisation du numéraire.



COMPRÉHENSION DU DOMAINE - STRUCTURE DU NUMÉRAIRE

Agen (Lot-et-Garonne)

Trouvailles: Bolsward, 1 ex. (H. 528) (1,26).

COMPRÉHENSION DU DOMAINE - L'ATELIER

Agen (Lot-et-Garonne)

COMPRÉHENSION DU DOMAINE - LE TYPE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés) + CARLVS REX FR croix + AGINNO monogramme Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 73 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 e

COMPRÉHENSION DU DOMAINE - LA NATURE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

COMPRÉHENSION DU DOMAINE - LA LÉGENDE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814) Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

COMPRÉHENSION DU DOMAINE - LES COLLECTIONS

Agen (Lot-et-Garonne)

COMPRÉHENSION DU DOMAINE - LES TRÉSORS

Agen (Lot-et-Garonne)

COMPRÉHENSION DU DOMAINE - LES TROUVAILLES

Agen (Lot-et-Garonne)

COMPRÉHENSION DU DOMAINE - SCÉNARIO D'ANNOTATION

Texte en entrée de notre chaîne de traitement

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)
Denier de Charlemagne (24 exemplaires étudiés)
+ CARLVS REX FR croix + AGINNO monogramme
Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;
Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

COMPRÉHENSION DU DOMAINE - SCÉNARIO D'ANNOTATION

Texte en sortie de notre chaîne de traitement Domaine annoté : Temporel .

Agen (Lot-et-Garonne)

Type de 793/4-812 : Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

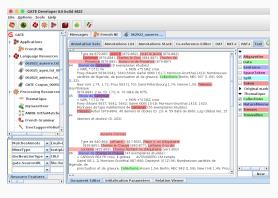
COMPRÉHENSION DU DOMAINE

Texte en sortie de notre chaîne de traitement Domaine annoté : Thématique .

```
Agen (Lot-et-Garonne)
 Type de 793/4-812 : Charlemagne (768-814)
 Denier de Charlemagne (24 exemplaires étudiés)
 + CARLVS REX FR croix
                           + AGINNO monogramme
Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;
 Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735
 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60),
 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex.
 (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);
Trouvailles: Bolsward, 1 ex. (H. 528) (1,26).
```

ANNOTATIONS DANS GATE

ANNOTATIONS DANS GATE



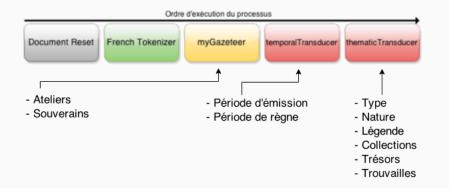
- Outil de traitement automatique du langage (en JAVA).
- Université de Sheffield depuis 1995 (version 8).
- Principe: Chaîne de traitement (Pipeline).
- Plusieurs modules dans un pipeline.
- ANNIE: Pipeline par défaut pouvant servir de chaîne de départ

ANNOTATIONS DANS GATE

Modules de traitement

Chaînes de traitement GATE Developer 8.0 build 4825 Messages French NE ▼ 基 Applications **Loaded Processing resources** Selected Processing resources Name Type Language Resources © 020208_mettalum. myGazetteer ANNIE Gazetteer © 062922 auxerre.txt temporel JAPE Transducer @ 063025_agen.txt_0 JAPE Transducer thematique Composition d'une Corpus à traiter © 062824 amiens.txt GATE Corpus_000 chaîne de traitement thematique temporel myGazetteer Corpus: GATE Corpus 0005C No selected processing resource Name Type Required Value

La chaîne de traitement LANG





■ Document reset : Réinitialisation du document



- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots



- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots
- MyGazetter : Identification de noms d'entités par Gazetier



- Document reset : Réinitialisation du document
- French Tokeniser : Découpage des phrases en mots
- MyGazetter : Identification de noms d'entités par Gazetier
- temporal/thematic Transducer : Repérage d'entités nommées inconnues en fonction de modèles d'extraction écrits en langage JAPE



■ liste de noms d'entités (Villes, métiers,etc)



- liste de noms d'entités (Villes, métiers, etc)
- permettant un repérage d'occurrences dans un texte



- liste de noms d'entités (Villes, métiers,etc)
- permettant un repérage d'occurrences dans un texte
- possibilité d'associer des caractéristiques a chaque nom d'entité (séparateurs)



- liste de noms d'entités (Villes, métiers,etc)
- permettant un repérage d'occurrences dans un texte
- possibilité d'associer des caractéristiques a chaque nom d'entité (séparateurs)
- Dans Gate: MajorType, MinorType réutilisable dans une règle JAPE

ANNOTATIONS DANS GATE - LE FORMALISME JAPE

- Règles IAPE en deux blocs
- Partie gauche (LHS): définition d'un motif d'annotation à repérer
- Partie droite (RHS): Opérations sur un motif (Code JAVA éventuel)
- Utilisation d'un système de Macros



MISE EN ŒUVRE - DÉMARCHE

1. Langage naturel

MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier

MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

expressions régulières

MISE EN ŒUVRE - DÉMARCHE

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

expressions régulières

JAPE

Annotation : La période d'émission

Exemple 1 : Type de 793/4-812

1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois chiffres. En cas d'ambiguïté, une date peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois chiffres. En cas d'ambiguïté, une date peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

Type de **793/4**-812

2. LANGAGE RÉGULIER

Type de **793/4-**812

2. LANGAGE RÉGULIER

Type de 793/4-812

2. LANGAGE RÉGULIER

Type de 793/4-812

2. LANGAGE RÉGULIER

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind==number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind==number,Token.length == 1})
Macro: LASH
({Token.string=="/"})
Macro: DATE_PRECISE
(TROIS_NOMBRES)
Macro: DATE_IMPRECISE
(TROIS_NOMBRES SLASH UN_NOMBRE)
Macro: DATE_IMPRECISE
(TROIS_PRECISE | DATE_IMPRECISE)
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ((Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind==number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind==number,Token.length == 1})
Macro: LASH
({Token.string=="/"})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES SLASH UN_NOMBRE)
Macro:DATE_OBATE_IMPRECISE
(TROIS_NOMBRES SLASH UN_NOMBRE)
Macro:DATE_OBATE_IMPRECISE
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind=number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind=number,Token.length == 1})
Macro:SLASH
({Token.string=="/"})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*...*/}
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

Annotation : La nature de la monnaie

Exemple 2 : Obole de Carloman

Obole de Carloman

1. LANGAGE NATUREL

La nature de la monnaie est toujours un élément de l'ensemble {Denier, Obole, Monnaie D'Or, Faux obole, Monnaies de type indéterminé} suivi du nom d'un souverain. Il suffit donc d'utiliser une expression composée de tous les mots de l'ensemble.

Obole de Carloman

2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (*)

Nom_Souverain

Obole de Carloman

2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (.*)

Nom_Souverain

Obole de Carloman

2. LANGAGE RÉGULIER

[\s]{2,}(Denier|Obole|Monnaie d'or|Faux Obole| Monnaies de type indéterminé) (.*) Nom_Souverain

Obole de Carloman

```
Macro: MONNAIE

(
({Token.string == "Obole"})|
({Token.string == "Denier"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Monnaie_d'or"})|
({Token.string == "Monnaies_de_type_indéterminé"})
)

Macro: LIAISON
((Token.string == "Monnaies_de_type_indéterminé"})

Macro: LIAISON
((Token.string == "de"))
```

Obole de Carloman

```
Macro: MONNAIE

( ({Token.string == "Obole"})| (({SpaceToken})?(MONNAIE):monnaie
(({Token.string == "Monnaie_d'or"})| (({SpaceToken})((LTAISON)({SpaceToken}))
(({Token.string == "Monnaie_d'or"})| ((ANgazetier.majorType == "rois"))
(({Token.string == "Monnaies_de_type_indéterminé"})
)

Macro: LIAISON
(({Token.string == "de"})
```

Obole de Carloman

MISE EN ŒUVRE - RÉSULTAT

Résultat d'annotation Fichier XML :

<PeriodeEmission>Type de 793/4-812/PeriodeEmission>

<NatureMonnaie>Obole de Carloman</NatureMonnaie>

MISE EN ŒUVRE - RÉSULTAT

Résultat d'annotation Fichier XML :

<PeriodeEmission>Type de 793/4-812/PeriodeEmission>

<NatureMonnaie>Obole de Carloman</NatureMonnaie>

Comment visualiser les annotations en dehors de GATE ?

MISE EN ŒUVRE - RÉSULTAT

Résultat d'annotation Fichier XML :

<PeriodeEmission>Type de 793/4-812/PeriodeEmission>

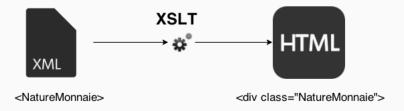
<NatureMonnaie>Obole de Carloman</NatureMonnaie>

Comment visualiser les annotations en dehors de GATE?

XSLT

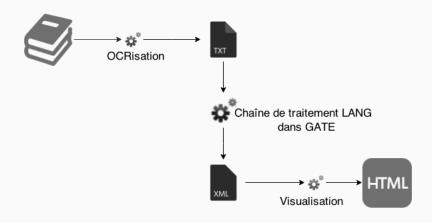


VISUALISATION



DÉMONSTRATION

CONCLUSION



CONCLUSION

■ Amélioration de la robustesse de l'application

CONCLUSION

- Amélioration de la robustesse de l'application