CONCEPTION ET DÉVELOPPEMENT D'UNE APPLICATION D'ANNOTATION THÉMATIQUE dans l'environnement Gate

Charles Follet Roland Bary

May 15, 2015

Université de Pau et Pays de l'Adour

INTRODUCT<u>ION</u>

■ Extension du web vers un web de dit de données: le web sémantique

- Extension du web vers un web de dit de données: le web sémantique
- Recherche sémantique: activité du web sémantique

- Extension du web vers un web de dit de données: le web sémantique
- Recherche sémantique: activité du web sémantique
- Annotation sémantique: Étape du processus de recherche sémantique

- Extension du web vers un web de dit de données: le web sémantique
- Recherche sémantique: activité du web sémantique
- Annotation sémantique: Étape du processus de recherche sémantique
- Problème: Comment annoter sémantiquement un document texte non-structuré ?

- Extension du web vers un web de dit de données: le web sémantique
- Recherche sémantique: activité du web sémantique
- Annotation sémantique: Étape du processus de recherche sémantique
- Problème: Comment annoter sémantiquement un document texte non-structuré ?
- Quelles outils pour l'annotation ?

- Extension du web vers un web de dit de données: le web sémantique
- Recherche sémantique: activité du web sémantique
- Annotation sémantique: Étape du processus de recherche sémantique
- Problème: Comment annoter sémantiquement un document texte non-structuré ?
- Quelles outils pour l'annotation?
- Quelle approche de conception ?

SOMMAIRE

Le cahier des charges

Cadre d'analyse

L'environnement GATE

Les Gazetiers

Le formalisme JAPE

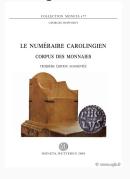
Structure du numéraire

Annotations

Construction d'une règle JAPE

Visualisation

Contexte: Recherche d'informations sur le Numéraire Carolingien de Georges DEPEYROT.



Exemples de recherches possibles:

- Temporelle: Quelles étaient les pièces en circulation de l'an 859 à l'an 865 ?
- Spatiale: Dans quels ateliers, les pièces de type Obole de Charlemagne ont été produites ?
- Thématique: Combien d'exemplaires de la monnaie d'or de Charles le Chauve ont été étudiés ?

Contexte: Recherche d'informations sur le Numéraire Carolingien de Georges DEPEYROT.



Exemples de recherches possibles:

- Temporelle: Quelles étaient les pièces en circulation de l'an 859 à l'an 865 ?
- Spatiale: Dans quels ateliers, les pièces de type Obole de Charlemagne ont été produites ?
- Thématique: Combien d'exemplaires de la monnaie d'or de Charles le Chauve ont été étudiés ?

Solution: Utilisation d'un outil de TAL: GATE

Caractéristiques du projets:

■ apprentissage et compréhension du domaine considéré

Caractéristiques du projets:

- apprentissage et compréhension du domaine considéré
- étude des principes d'annotation de documents

Caractéristiques du projets:

- apprentissage et compréhension du domaine considéré
- étude des principes d'annotation de documents
- développement d'une chaîne d'annotation dans GATE

Caractéristiques du projets:

- apprentissage et compréhension du domaine considéré
- étude des principes d'annotation de documents
- développement d'une chaîne d'annotation dans GATE
- mise en place d'une interface web de visualisation des résultats

Scénario attendu: Texte en entrée de traitement

Auxerre (Yonne

Type de 840-864: Lothaire I (817-855), Pépin II, roi d'Aquitaine (839-865), Charles le Chauve (840-877), Lothaire II roi de Lorraine (855-869), Charles l'Enfant roi d'Aquitaine (vers 860)

+ CAROLVS REX FR crox. 4 globes AVTSIODERO CM temple Garal W3.1 2; Morrison-Grunthal 887-990: Depsyrt 01 () 29 6; Hombreuses variétés de légende, de ponctuation et de gravure. Collections: Assen 1,54; Berlin, MEC 842 (1,59); New York 1,49; Prou 522 (1,63); 833 (1,46). Trésors: Groningen-1890 (vers 940), 1 ex. (MG 38; H. 3), daté de 845-846); Auxerre (840-845), 1 ex. (D. 24); Tzummarum (840-845), 1 ex. (H. 22 daté de 840, ne mentionne pas cette monnaie dans le catalogue); Cosne (840-945), 30 ex. (D. 109; H. 45, daté de 845-846, voir de 869-870); B. (D. 109; M. 45, daté de 845-846, voir de 869-870); Roswinkel (875), 1 ex. (M 66; H. 75 daté de 867); (1,53); Trouvalles: Auxerre, 1875, March 1875,

Type de 864-875: Charles le Chauve (840-877), Louis le Germanique (840-876), Louis II le Bègue roi d'Aquitaine (867-877), de France (877-879) Denier de Charles le Chauve (22 exemplaires étudiés)

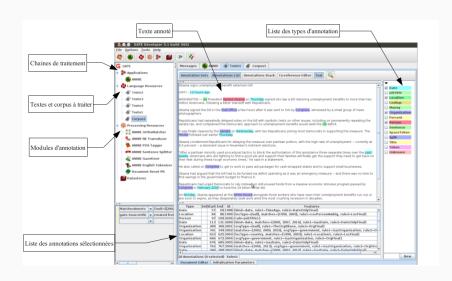
98 Denier de Charles le Chauve (1 exemplaire étudié) + GRATIA DEI REX monogramme + ALTIEI CIVITVS (rétro.) croix Gariel XXV 24; Morrison-Grunthal 991; Depeyrot (1) (2) 98; Collections: Prou 589 (1,68).

Scénario attendu: Texte en sortie de traitement

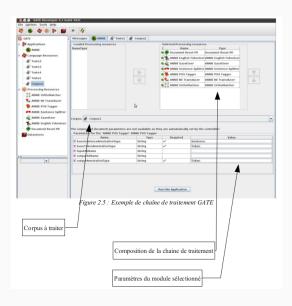
Auxerre (Vonne) Type de 840-864: Lothaire I (817-855), Pépin II, roi d'Aquitaine (839-865), Charles le Chauve (840-877), Lothaire II roi de Lorraine (855-869), Charles l'Enfant roi d'Aquitaine (vers 860) Denier de Charles le Chauve (43 exemplaires étudiés) + CAROLVS REX FR croix, 4 globes AVTISIODERO CIVI temple Gariel XXI 1, 2: Morrison-Grunthal 987-990; Depeyrot (I) (2) 96; Nombreuses variétés de légende, de ponctuation et de gravure, Collections: Assen 1,54; Berlin: MEC 842 (1,59); New York 1,49; Prou 582 (1.63), 583 (1.46). Trésors: Groningen-1890 (vers 840), 1 ex. (MG 38; H, 39, daté de 845-846); Auxerre (840-845), 1 ex. (D. 24); Tzummarum (840-845), 1 ex. (H. 22 daté de 840, ne mentionne pas cette monnaie dans le catalogue); Cosne (840-845), 30 ex, (D. 109; H. 45, daté de 845-846, voir p. 93): Midlaren (855), 1 ex. (MG 55; H. 57 daté de 864); Nourray (869-875), 1 ex. (D. 243; H. 64 daté de 869-870): Roswinkel (875): 1 ex. (MG 66: H. 75 daté de 877) (1.55): Trouvailles: Auxerre 1. ex. (H. 511) Type de 864-875: Charles le Chauve (840-877), Louis le Germanique (840-876), Louis II le Bèque roi d'Aquitaine (867-877) de France (877-879) Denier de Charles le Chauve (22 exemplaires étudiés) + AVTISIODER CIVITAS croix + GRATIA DEI REX monogramme Gariel XXV 20-23; Morrison-Grunthal 991, 994, 996-1001; Depeyrot (1) (2) 97; Nombreuses variétés de légende, de ponctuation et de gravure (AVTISIODER CM), Collections: Berlin 1.77, 1.70, 1.59. 1.55; MEC 853 (1.78); Monnale de Paris 105 (1.63); Prou 584 (1.58), 585 (1.69), 586 (1.79), 587 (1,72), 588 (1,77), Trésors: Fontaines/Mercurey (840-875), 1 ex. (D. 147 ne mentionne pas cette monnale: H, 66 daté de 875); Cosne (875-877), 2 ex, (D, 110; H, 67 daté de 875) (1,74, 1,73); Montrieux-en-Sologne (887-898), 4 ex. (D. 231; H. 88 daté de 888); Glisv (890), 3 ex. (D. 154; H. 90 daté de 888), Monchy-au-Bois (895-898), 1 ex. (D. 217; H. 101 daté de 897-898); Montrieux-en-Sologne (900), 1 ex. (D. 229; H. 87 daté de 888). 98 Denier de Charles le Chauve (1 exemplaire étudié) + GRATIA DEI REX monogramme + ALTIEI CIVITVS (rétro.) croix Garriel XXV 24: Morrison-Grunthal 991: Depeyrot (1) (2) 98: Collections: Prou 589 (1.68).

CADRE D'ANALYSE

CADRE D'ANALYSE - GATE



CADRE D'ANALYSE - GATE



CADRE D'ANALYSE - GAZETIERS

```
rols.lst
1 Pépin le Bref:valeur=Pépin le Bref:periode=752-768
     Adalbert Lothaire:valeur=Adalbert Lothaire:periode=954-986
     Amoul roi de Germanie:valeur=Amoul roi de Germanie:periode=887-899
     Bérenger I:valeur=Bérenger I:periode=888-924
     Bérenger II:valeur=Bérenger II:periode=958-961
     Boson roi de Provence:valeur=Boson roi de Provence:periode=879-887
     Carloman:valeur=Carloman:periode=768-771
     Carloman:valeur=Carloman:periode=879-884
     Charlemagne:valeur=Charlemagne:periode=768-814
     Charles de Provence:valeur=Charles de Provence:periode=876-880
     Charles l'Enfant roi d'Aquitaine:valeur=Charles l'Enfant roi d'Aquitaine:periode=vers 860
     Charles le Chauve:valeur=Charles le Chauve:periode=840-877
     Charles le Gros:valeur=Charles le Gros:periode=884-887
     Charles le Simple:valeur=Charles le Simple:periode=898-929
     Conrad le Pacifique:valeur=Conrad le Pacifique:periode=937-993
     Eudes:valeur=Eudes:periode=887-898
     Gui de Spolète:valeur=Gui de Spolète:periode=891-894
     Henri l'Oiseleur:valeur=Henri l'Oiseleur:periode=918-947
     Hugues de Provence:valeur=Hugues de Provence:periode=926-947
    Lambert empereur:valeur=Lambert empereur:periode=894-898
     Lothaire d'Italie:valeur=Lothaire d'Italie:periode=931-950
     Lothaire I:valeur=Lothaire I:periode=817-855
     Lothaire II roi de Lorraine: valeur=Lothaire II roi de Lorraine: periode=855-869
     Louis II le Bèque:valeur=Louis II le Bèque:periode=877-879
     Louis II le Bèque roi d'Aquitaine:valeur=Louis II le Bèque roi d'Aquitaine:periode=867-877), de France (877-879
     Louis III:valeur=Louis III:periode=879-882
     Louis III:valeur=Louis III:periode=898-929
     Louis IV d'Outre-Mer:valeur=Louis IV d'Outre-Mer:periode=936-954
     Louis IV l'Enfant:valeur=Louis IV l'Enfant:periode=899-912
     Louis l'Aveugle roi de Provence:valeur=Louis l'Aveugle roi de Provence:periode=890-929
     Louis le Germanique:valeur=Louis le Germanique:periode=840-876
     Louis le Germanique:valeur=Louis le Germanique:periode=870-876
     Louis le Jeune:valeur=Louis le Jeune:periode=879-882
    Louis le Pieux:valeur=Louis le Pieux:periode=814-840
    Louis le Pieux roi d'Aguitaine:valeur=Louis le Pieux roi d'Aguitaine:periode=781-814
     Louis V:valeur=Louis V:periode=986-987
37 Otton I:valeur=Otton I:periode=936-973) ou Otton II (973-983) (frappes germaniques pour mémoire
     Pépin I roi d'Aquitaine:valeur=Pépin I roi d'Aquitaine:periode=817-838
     Pépin II. roi d'Aquitaine:valeur=Pépin II. roi d'Aquitaine:periode=839-865
     Raoul:valeur=Raoul:periode=923-936
```

CADRE D'ANALYSE - JAPE

```
Phase: pourcent
Input: Lookup Token
Options: control = appelt
Macro: AMOUNT NUMBER
(({Token.kind == number}
({Token.string == ","} | {Token.string == "."})
{Token.kind == number}
)?
({Token.string == "-"}{Token.kind == number})?))
Macro: PERCENT(
{Token.string == "%"} |
{Token.string == "pourcent"}|
({Token.string == "pour"}{Token.string == "cent"})
14)
Macro: LIAISON PERCENT DE ET(
{Token.string == "de"}|
{Token.string == "et"}|
{Token.string == ","})
Rule: Percent number
(((AMOUNT NUMBER)
({Token.string == "'
a"})
)?(AMOUNT NUMBER)(PERCENT))
:pourcent -->:pourcent.Percent = {Kind="pourcent",Rule="Percent number"}
```



EXEMPLE

Agen (Lot-et-Garonne)

L'ATELIER

Agen (Lot-et-Garonne)

LE TYPE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)
+ CARLVS REX FR croix + AGINNO monogramme
Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;
Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

LA NATURE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814)

Denier de Charlemagne (24 exemplaires étudiés)

LA LÉGENDE

Agen (Lot-et-Garonne)

Type de 793/4-812: Charlemagne (768-814) Denier de Charlemagne (24 exemplaires étudiés)

+ CARLVS REX FR croix + AGINNO monogramme

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45; Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735 (1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex. (MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35);

LES COLLECTIONS

Agen (Lot-et-Garonne)

LES TRÉSORS

Agen (Lot-et-Garonne)

LES TROUVAILLES

Agen (Lot-et-Garonne)

RÉSUMÉ

```
Agen (Lot-et-Garonne) ATELIER

Type de 793/4-812: Charlemagne (768-814) TYPE

Denier de Charlemagne (24 exemplaires étudiés) NATURE

+ CARLVS REX FR croix  + AGINNO monogramme LÉGENDE

Gariel XXII 26; Morrison-Grunthal 177-179; Depeyrot (1) (2) 1; Collections: Berlin 1,64, 1,45;

Bruxelles 1,25, 1,25; Charleville-Mézières 1,56; Copenhague 1,31; Garett 1,73; Grenoble; MEC 735

(1,57), 736 (1,24); Monnaie de Paris 88 (1,55); New York 1,64, 1,57; Prou 792 (1,36), 793 (1,60), 794 (1,50) COLLECTIONS Trésors: Biebrich (790-814), 2 ex. (MG 11, Vôlkers, p. 182) (1,60); Ibersheim (814), 1 ex.

(MG 13, Vôlkers, p. 186) (1,64); Dorestad (822), 4 ex. (MG 18, Vôlkers, p. 139; H. 7) (1,35); TRÉSORS

Trouvailles: Bolsward, 1 ex. (H. 528) (1,26) TROUVAILLES.
```

ANNOTATIONS

DEUX FAÇONS D'ANNOTER

GAZETIER

liste de valeurs.

- · Type de 754/5-768
- · Type de 768-771
- · Type de 771-793/4
- · Type de 793/4-812
- · Type de 812-814

٠.

RÈGLE JAPE

règle basée sur une expression régulière.

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

// Exemple : Type de 758/9-762
Rule: PeriodeEmissionRule
    (
    CHAINE_DEBUT ({Periode}):p
):PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {
    Kind = "PeriodeEmission",
    D1 = :p.Periode.D1, D2 = :p.Periode.D2
}
```

DEUX FAÇONS D'ANNOTER

GAZETIER

liste de valeurs.

- · Type de 754/5-768
- · Type de 768-771
- · Type de 771-793/4
- · Type de 793/4-812
- · Type de 812-814
- ...

RÈGLE JAPE

règle basée sur une expression régulière.

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ((Token.string =="de"})((SpaceToken))
)

// Exemple : Type de 758/9-762
Rule: PeriodeEmissionRule
(
    CHAINE_DEBUT ({Periode}):p
):PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {
    Kind = "PeriodeEmission",
    D1 = :p.Periode.D1, D2 = :p.Periode.D2
}
```

CONSTRUCTION D'UNE RÈGLE JAPE

1. Langage naturel

- 1. Langage naturel
- 2. Langage régulier

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français expressions régulières

- 1. Langage naturel
- 2. Langage régulier
- 3. Langage de programmation

français

expressions régulières

JAPE

Annotation : La période d'émission

Exemple : Type de 793/4-812

Type de 793/4-812

1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois et seulement trois chiffres. En cas d'ambiguïté, chacune d'entre elles peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

Type de 793/4-812

1. LANGAGE NATUREL

Une période est un intervalle entre deux dates. Dans notre travail, les dates sont constituées de trois et seulement trois chiffres. En cas d'ambiguïté, chacune d'entre elles peut être suivie d'un / et d'un chiffre traduisant l'indétermination de la date.

Il faut assurer la capture de la période d'émission en ajoutant la contrainte précédée de "Type de" afin de ne pas récupérer toutes les périodes du document.

Type de **793/4**-812

2. LANGAGE RÉGULIER

Type de **793/4-**812

2. LANGAGE RÉGULIER

Type de 793/4-812

2. LANGAGE RÉGULIER

Type de 793/4-812

2. LANGAGE RÉGULIER

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
((Token.kind=number,Token.length == 3})
Macro: UN_NOMBRE
((Token.kind=number,Token.length == 1})
Macro:SLASH
({Token.string=="/"})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind=number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind=number,Token.length == 1})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
```

```
Rule: PeriodeRule
((DATE):d1({Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {75...7/}
```

```
Macro: CHAINE_DEBUT
(
    ({Token.string =="Type"})({SpaceToken})
    ({Token.string =="de"})({SpaceToken})
)

Macro: TROIS_NOMBRES
({Token.kind=number,Token.length == 3})
Macro: UN_NOMBRE
({Token.kind=number,Token.length == 1})
Macro:SLASH
({Token.string=="/"})
Macro:DATE_PRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
Macro:DATE_IMPRECISE
(TROIS_NOMBRES)
```

```
Rule: PeriodeRule
((DATE):d1((Token.string =="-"})(DATE):d2)
:Periode -->:Periode{/*...*/}

Rule: PeriodeEmissionRule
(CHAINE_DEBUT ({Periode}):p)
:PeriodeEmission
-->:PeriodeEmission.PeriodeEmission = {/*..*/}
```

